HW2 / CRISP-DM

洪水機率預測
多元線性回歸與特徵選擇

學號：5115056023 | 實驗日期：2026-10-16

資料：Kaggle Flood Prediction Dataset，version 1，50,000 筆、20 個輸入特徵。

文件狀態：分析報告已產出；完整 GPT 對話 PDF 尚待補入，這不是完整繳交版。

主要發現

開發資料顯示目標幾乎是 20 個特徵的等權線性和，因此完整 OLS 的測試 R^2 為 1。這是資料生成結構的結果，不能解讀為對真實洪災有完美預測能力。

資料切分	筆數	用途
開發集	30,000	五折交叉驗證、特徵選擇、模型訓練
校準集	10,000	僅建立 split-conformal 預測區間
最終測試集	10,000	方案鎖定後評估，不用來挑模型

正式模型：OLS full。測試 MSE = 4.320e-32；RMSE = 2.079e-16；R^2 = 1.000000。

完整模型區間涵蓋率 98.07%，平均寬度 8.883e-16（浮點誤差尺度）。14 特徵示範涵蓋率 94.58%，平均寬度 0.109018。

閱讀路線

商業與資料理解 → 資料準備 → 建模與特徵選擇 → 評估與預測區間 → 假設診斷 → 研究比較 → AI 協作與證據 → 部署與參考來源。

1. Business Understanding | 商業理解

任務是用 20 項環境與社會因素分數，預測連續目標 FloodProbability。此為監督式迴歸，使用 scikit-learn 線性模型比較特徵保留數與正則化的影響。

教學驗收以正確可重現的流程、相對平均值基準的誤差、區間涵蓋率，以及對資料限制的說明為主。沒有實際防災成本資料，也沒有指定可上線的誤差門檻。

1.1 資料來源與授權

實際採用 Kaggle 上 Kamrul Hasan 重新上傳的公開版本：[1]，而非需要邀請的 Predict the Flood 競賽，也不是 Playground S4E5 的百萬筆競賽版本。原先常見的 brijlaldhankour 原始連結目前無法取得。

https://www.kaggle.com/datasets/kamrulhasan0077/flood-prediction-dataset

Kaggle 官方 API 標示 CC0: Public Domain，version 1。下載後保存原始 metadata、來源 JSON 和 SHA-256。這項授權標示不代表已驗證資料真實來源。

上傳者承認外部原始來源、蒐集方式與地理覆蓋範圍不明。本地觀察到近乎確定的生成公式，只能說具有生成式教學資料的特徵；不能聲稱已獨立查證它是真實量測或確定某種合成方式。

1.2 能與不能解釋的事情

可以展示線性擬合、正則化、選特徵、資料洩漏防範及預測區間。不能將資料中分數視為具真實物理單位，也不能將迴歸係數當作防災措施的因果效果。

未提交 Kaggle，沒有競賽名次。外部競賽解法的分數只作研究脈絡，不當成同一資料切分下的公平實驗對照。

2. Data Understanding｜資料理解

實際 CSV 有 50,000 筆、21 欄。其中 20 個輸入欄位為 int64，FloodProbability 為 float64；來源描述「全部 int64」與實際檔案不符，分析以 CSV 為準。

缺值總數：0；重複列：0；目標範圍：[0.285, 0.725]。無 id、時間或地理識別欄位。

輸入特徵（不含目標）	中文理解	開發集範圍
MonsoonIntensity	季風強度	0 ~ 16
TopographyDrainage	地形排水	0 ~ 16
RiverManagement	河川管理	0 ~ 16
Deforestation	森林砍伐	0 ~ 17
Urbanization	都市化	0 ~ 17
ClimateChange	氣候變遷	0 ~ 16
DamsQuality	水壩品質	0 ~ 15
Siltation	淤積	0 ~ 15
AgriculturalPractices	農業作法	0 ~ 16
Encroachments	侵占河道	0 ~ 16
IneffectiveDisasterPreparedness	災害準備不足	0 ~ 16
DrainageSystems	排水系統	0 ~ 16
CoastalVulnerability	沿海脆弱度	0 ~ 16
Landslides	山崩	0 ~ 16
Watersheds	集水區	0 ~ 16
DeterioratingInfrastructure	基礎設施劣化	0 ~ 16
PopulationScore	人口分數	0 ~ 19
WetlandLoss	濕地流失	0 ~ 17
InadequatePlanning	規劃不足	0 ~ 15
PoliticalFactors	政治因素	0 ~ 16

欄位中文僅協助理解名稱。對照真實量測的編碼規則及「高分是好或壞」並未得到可信證實，因此不按字面強加係數方向。完整統計量另見 outputs/development_description.csv。

2.1 探索圖與生成機制核對

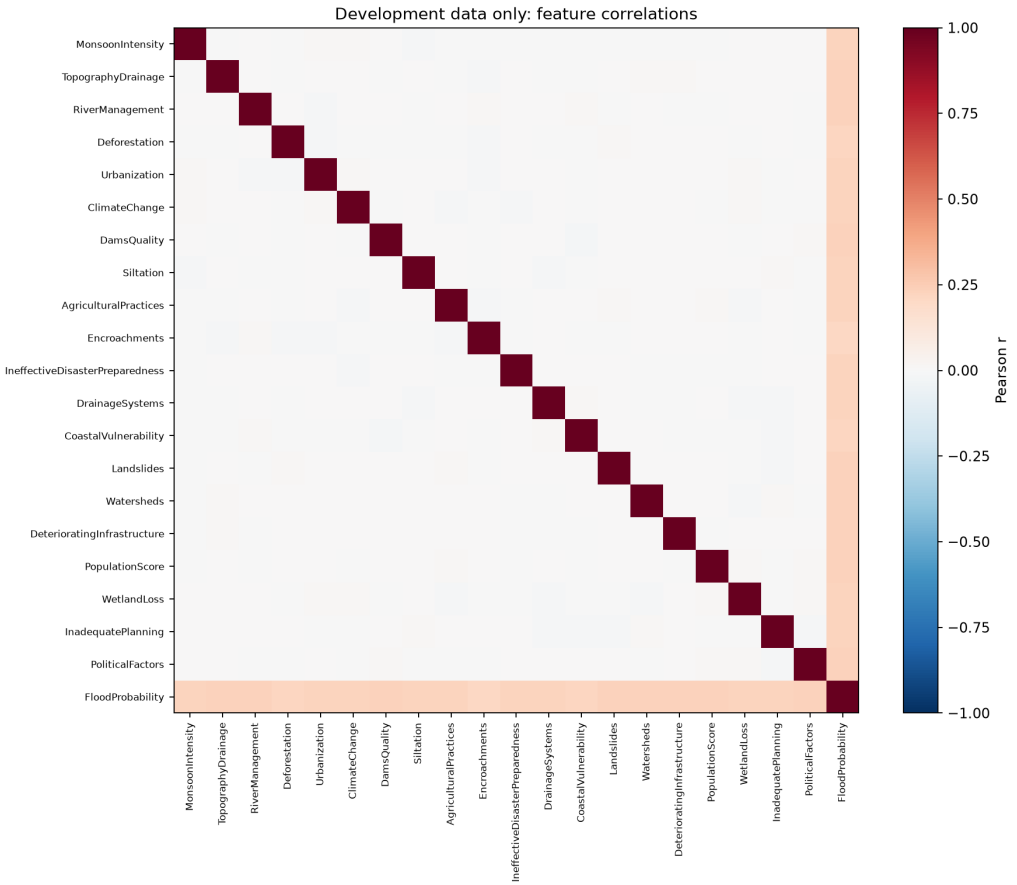


圖 1：僅使用開發資料的相關矩陣。各輸入彼此相關性低，不代表資料具有真實水文意義。

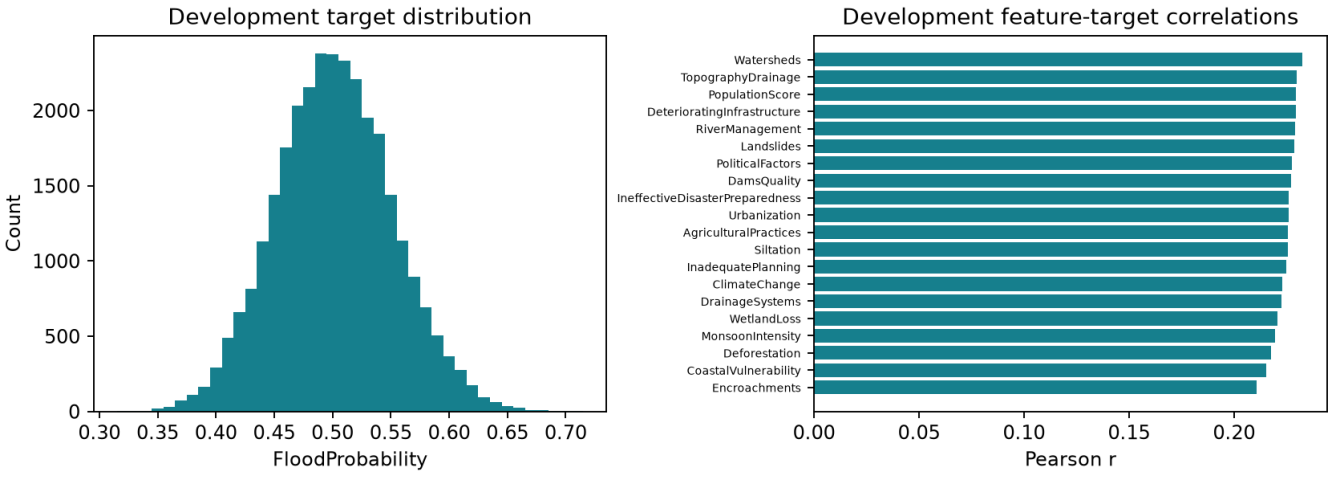


圖 2：開發集目標分布及特徵與目標的相關性。

額外以開發集的「特徵總和」擬合一維直線，得到斜率 0.005000000000、截距 5.995e-15，最大絕對誤差 2.554e-15。因此近似關係為 FloodProbability = 0.005 × sum(20 features)。

此核對不使用校準或測試目標，不將目標放入輸入欄位。它揭露資料設計限制，並解釋為何少留任何特徵都可能失去必要資訊。

3. Data Preparation | 資料準備

步驟	具體設定
固定切分	先以 random_state=42 保留 20% 測試，再將其餘資料的 25% 作校準；形成 60/20/20。
前處理	SimpleImputer(median) → StandardScaler → selector → regressor。每個 CV 訓練折自行擬合，驗證折只 transform。
五折驗證	KFold(n_splits=5, shuffle=True, random_state=42)，所有方案使用同樣折。
選擇器抽樣	每個 CV 訓練折內固定種子最多抽 2,500 筆學習特徵子集，降低 SFS 與 permutation 的成本；最後回歸用完整訓練折。
保留資料	校準標籤不參與排名；測試標籤不參與排名或調參。所有切分索引保存於 split_indices.json。

選擇器學習所用子樣本，是實驗的計算預算設計。完整資料仍參與每折回歸和驗證。不能把選擇器抽樣造成的排名當成穩定、唯一的重要性結論。

SFS 在每個訓練折內的子樣本做三折前向搜尋；已計算的相同訓練資料順序可快取重用，不跨驗證折分享選特徵結果。Permutation 在子樣本內另切 70/30，僅用其中驗證部分計算負 MSE 重要性。

Lasso 特徵排序使用子樣本內三折 LassoCV 的係數絕對值；最後保留指定 k 個後以 OLS 重擬合。指定 k 的排序法不等同單純只保留非零係數。前處理的參數仍完全限制在外層訓練折內。

可重現與誠實比較

來源版本、檔案 SHA-256、套件版本、抽樣上限、種子、原始 CV 各折分數與選定特徵列表均保存。未因最終測試表現修改超參數。多方案搜尋的 CV 最小值可能樂觀，保留測試作最終評估。

4. Modeling｜建模與特徵選擇

方案	實際設定
平均值基準	DummyRegressor，預測開發資料平均值。
完整 OLS	LinearRegression，20 特徵，截距項。
Ridge	alpha = 0.01, 0.1, 1, 10, 100, 1000；使用標準化輸入。
Lasso	alpha = 1e-6, 1e-5, 1e-4, 1e-3, 0.01，max_iter=20000。
SelectKBest	f_regression 單變量 F 分數排序。
RFE	標準化後以 LinearRegression 逐步消除低係數特徵。
Forward SFS	逐一加入讓內部三折 MSE 最小的特徵。
Lasso selection	LassoCV 九個 alpha，以絕對係數選指定 k。
Permutation	訓練內部驗證，五次置換的負 MSE 下降量排序。
非線性對照	HistGradientBoostingRegressor，固定參數，同樣 CV；不參與主要線性模型選擇。

五種特徵選擇各比較 k = 14、16、18、20，合計 20 個設定。k=20 時不刪特徵，因此五種名稱其實都回到完整 OLS。這些重複設定用於方法對照，不能解讀成五個不同的最佳模型。

全部比較 34 個設定（包含基準及非線性對照）。以線性方案的開發集五折平均 MSE 最小者為正式模型；完全同分時採用名稱清楚的 OLS full。正式模型為 OLS full。

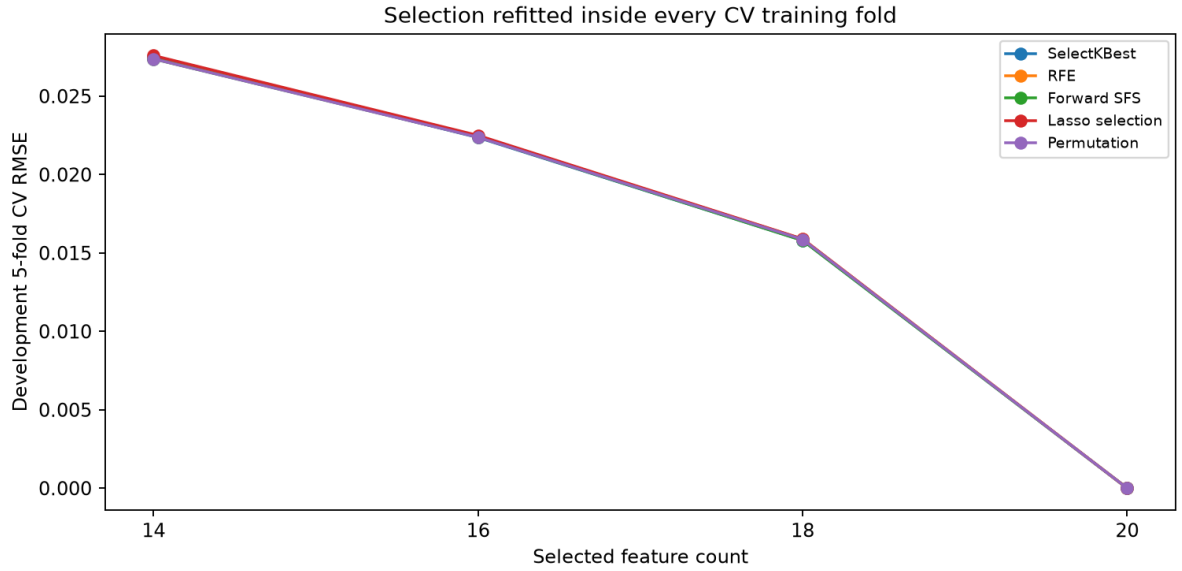


圖 3：特徵數與交叉驗證 RMSE。刪特徵後誤差增加符合等權生成機制。

4.1 前 20 名開發集 CV 設定

排名依 CV MSE；同分名稱排序僅方便列示。k=20 的六個 OLS 設定實際等價。此表不是以 Test MSE 排名。

設定	k	CV MSE	CV RMSE
Forward SFS k=20	20	1.013e-31	3.183e-16
Lasso selection k=20	20	1.013e-31	3.183e-16
OLS full	20	1.013e-31	3.183e-16
Permutation k=20	20	1.013e-31	3.183e-16
RFE k=20	20	1.013e-31	3.183e-16
SelectKBest k=20	20	1.013e-31	3.183e-16
Ridge alpha=0.01	20	4.310e-16	2.076e-08
Ridge alpha=0.1	20	4.310e-14	2.076e-07
Ridge alpha=1	20	4.310e-12	2.076e-06
Lasso alpha=1e-06	20	1.989e-11	4.460e-06
Ridge alpha=10	20	4.306e-10	0.000021
Lasso alpha=1e-05	20	1.988e-09	0.000045
Ridge alpha=100	20	4.274e-08	0.000207
Lasso alpha=0.0001	20	1.988e-07	0.000446
Ridge alpha=1000	20	3.974e-06	0.001993
Lasso alpha=0.001	20	0.000020	0.004459
Histogram gradient boosting (comparison)	20	0.000217	0.014737
Forward SFS k=18	18	0.000249	0.015791
SelectKBest k=18	18	0.000250	0.015804
Permutation k=18	18	0.000252	0.015860

完整各折分數見 outputs/cv_folds.csv；所有 34 個設定見 cv_ranking.csv。特徵選擇的各方案最終欄位列表見 selected_features.json。

5. Evaluation | 模型評估

模型	MAE	MSE	RMSE	R^2
Mean baseline	0.039827	0.002491	0.049913	-0.000288
OLS full	1.635e-16	4.320e-32	2.079e-16	1.000000
Ridge alpha=0.01	1.318e-08	2.728e-16	1.652e-08	1.000000
Lasso alpha=1e-06	3.540e-06	1.967e-11	4.435e-06	1.000000
SelectKBest k=14	0.022003	0.000766	0.027678	0.692409
SelectKBest k=16	0.017917	0.000508	0.022531	0.796180
SelectKBest k=18	0.012752	0.000259	0.016104	0.895877
HistGB 對照	0.011039	0.000210	0.014503	0.915549

MAE 為平均絕對誤差；MSE 為誤差平方平均；RMSE 與目標同尺度；R^2 相對常數平均值解釋變異，可以小於零。Adjusted $R^2 = 1 - (1-R^2)(n-1)/(n-k-1)$。本作業測試 n=10000，OLS 使用名目輸入數 k；對懲罰或非線性模型只作描述，不等同有效自由度調整。

正式模型的 Adjusted R^2 = 1.000000。原始輸出超出 0～1 的筆數為 0；不自動裁切。裁切後 MSE = 4.320e-32，只作敏感度比較，不改變正式排名。

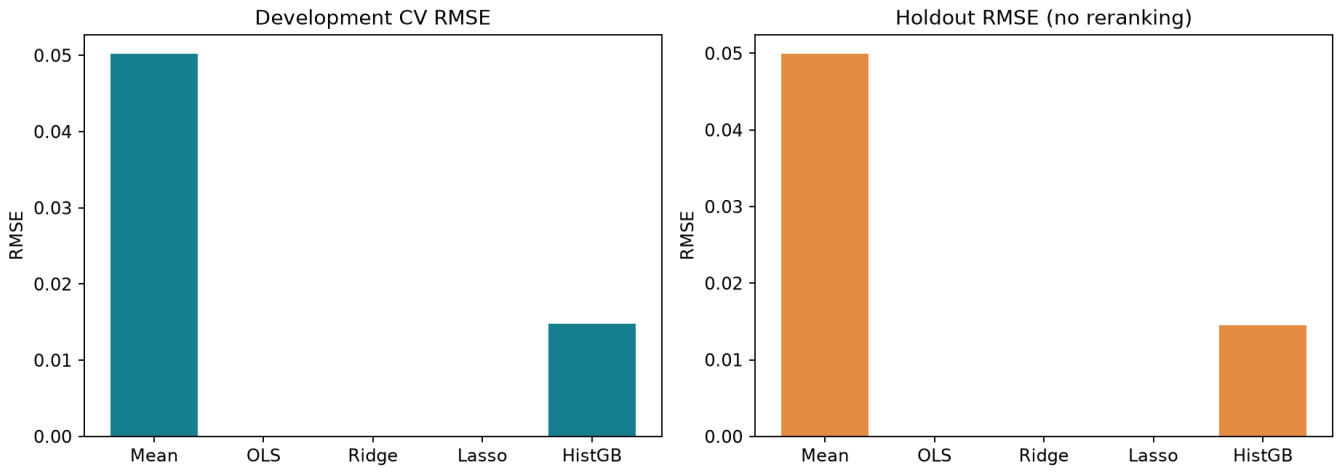


圖 4：同一資料與切分下，基準、線性與非線性方法比較。此版本結構線性，複雜模型未必更好。

5.1 預測圖與 95% 預測區間

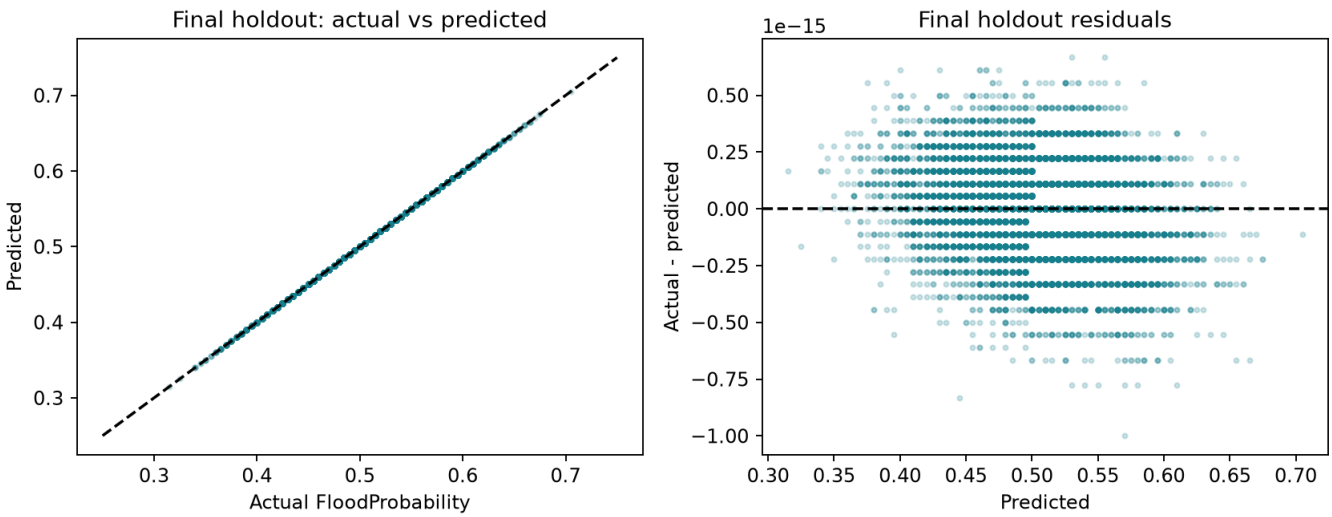


圖 5：正式模型實際值對預測值及測試殘差。微小殘差在 1e-16 尺度，只是浮點計算誤差。

區間採 split conformal [5]。模型在 30,000 筆開發資料擬合後凍結，校準集分數 $s_i = |y_i - f(x_i)|$。取 $\text{ceil}((10000+1) \times 0.95) = 9501$ 的排序分數 q，輸出 $[f(x)-q, f(x)+q]$。

它是新觀測目標的預測區間，不是平均迴歸線的信賴區間。在資料交換性假設下提供有限樣本邊際涵蓋率；不保證每個固定輸入的條件涵蓋率，也不保證分布改變後仍有效。校準集不可再用來調整模型或挑選區間寬度。

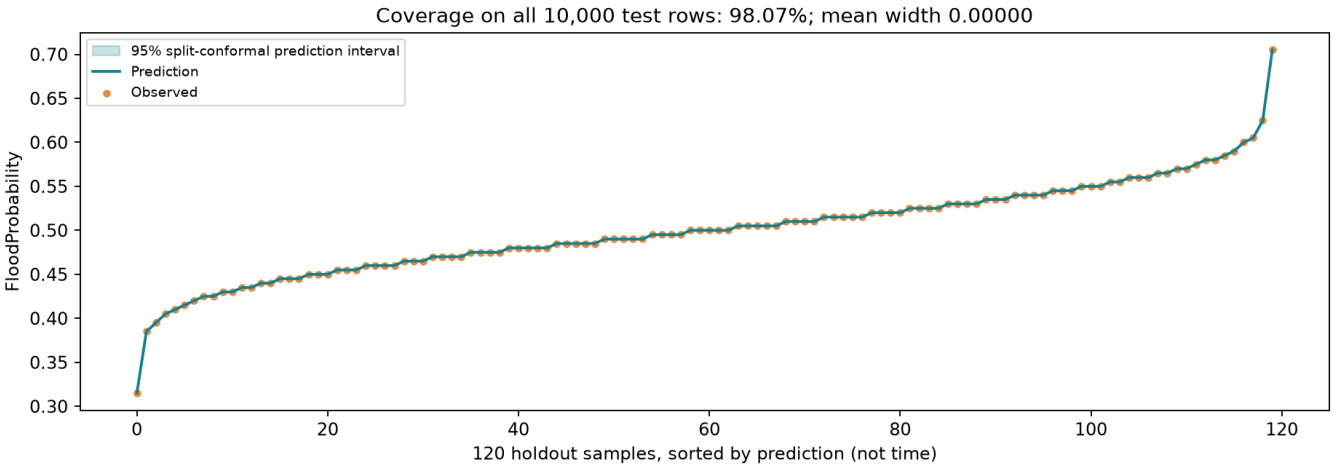


圖 6：完整模型 95% 區間。全體測試涵蓋率 98.07%，平均寬度 8.883e-16。圖中 120 筆依預測值排序，並非時間順序。

此資料的完整模型幾乎沒有隨機殘差，區間退化到浮點精度。離散分數與數值誤差會使實測涵蓋率高於名目值；不代表真實洪災風險沒有不確定性。

5.2 刪減特徵的區間示範

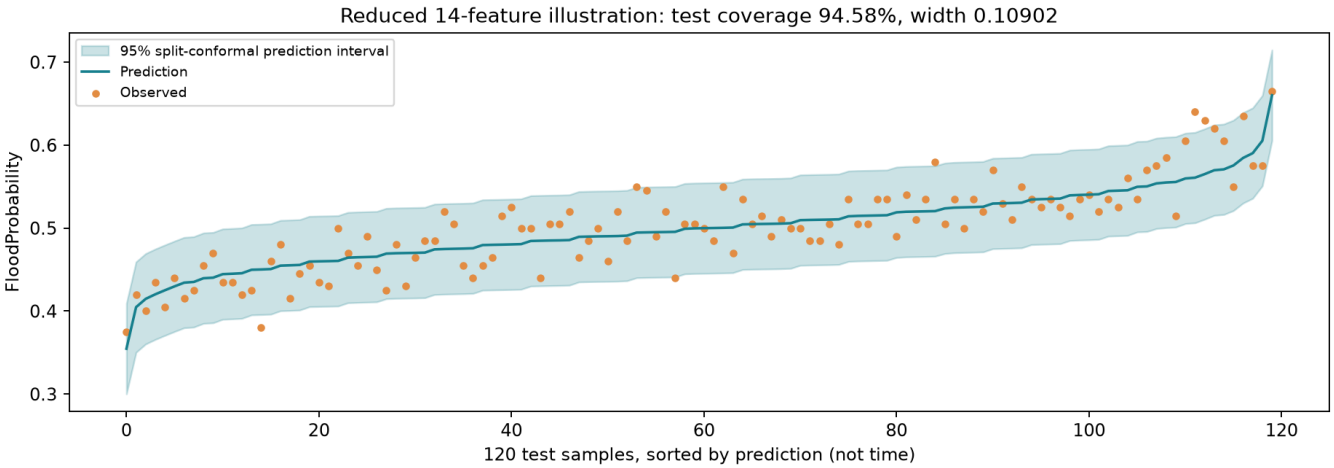


圖 7：固定 SelectKBest k=14 的預測區間。刪去因素後產生資訊損失，區間有可辨識的寬度。

項目	完整 OLS	14 特徵示範
名目涵蓋率	95%	95%
半寬 q	4.441e-16	0.054509
測試涵蓋率	98.07%	94.58%
平均寬度	8.883e-16	0.109018

14 特徵模型是預先定義的資訊損失示範，不因為區間較好看就改選它為正式模型。兩個模型分別用同一組獨立校準資料建立區間；沒有挑選校準分數最漂亮的模型。單次測試的 94.58% 不必恰好等於 95%，不能把一次實驗誤認為保證失效。

本機評估使用原始、未裁切的區間。若實際應用要將區間與 [0,1] 相交，必須揭露處理方式並另外檢查交換性、量測定義與外部有效性。

5.3 五項回歸假設檢查

假設	完整 OLS 與資料限制	14 特徵探索診斷
線性	開發集生成關係近似精確線性；殘差為浮點誤差，RESET 不解讀。	RESET p=0.09062；配合殘差圖，不以未拒絕當成已證明。
誤差獨立性	沒有時間 / 空間座標，不能建立合理排序，獨立性未被驗證。	DW=2.0013，僅原始列序描述，不作正式獨立性結論。
等變異	浮點殘差下 BP 會受數值結構支配，標為不適用。	BP p=0.1955，僅選特徵後探索性檢查。
常態性	殘差近零不形成可解釋的隨機分布，JB 不適用。	JB p=2.001e-36；配合 Q-Q 圖，留意大樣本敏感性。
多重共線性	最大 VIF=1.0011；標準化設計矩陣秩=21。	欄位近獨立；低 VIF 不等於具有因果意義。

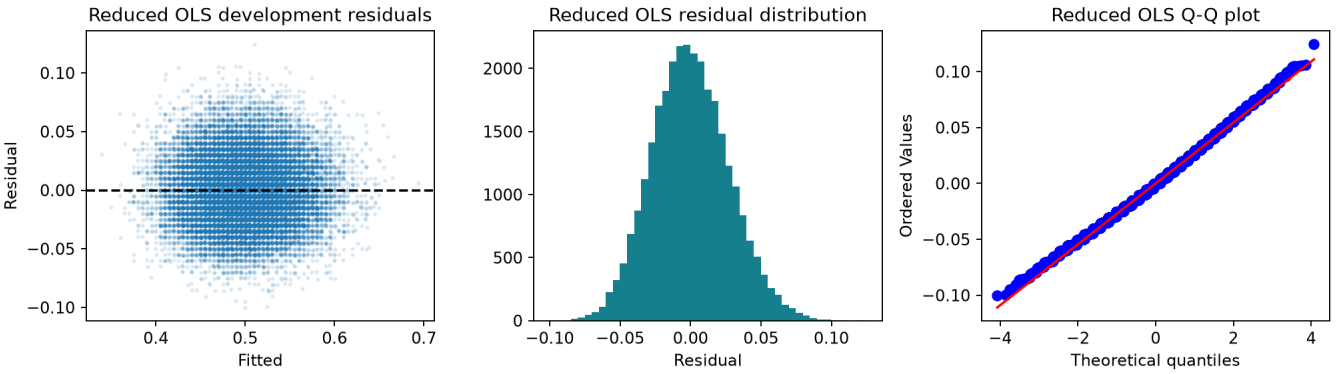


圖 8：14 特徵模型在開發集的殘差、分布及 Q-Q 圖，提供非退化的診斷示範。

14 特徵診斷是在選特徵後進行，p 值未校正選擇程序，僅供探索。完整模型殘差標準差約 2.086e-16；程式刻意將不適用的正式檢定輸出設為 null，而不呈現誤導的顯著性。

OLS 點估計不要求誤差必然常態；常態性主要關係傳統小樣本推論。Split conformal 不依賴殘差常態或等變異，但仍需要交換性，且固定寬度區間不保證條件涵蓋。

6. 同題研究與主流方法比較

研究來源在報告 [1] ~ [5] 與 RESEARCH_SOURCES.md 中可追溯。不同版本的洪水資料不應只憑相同欄名就混用。

方法 / 來源	可借鏡之處	比較限制
同題線性回歸 [2]	以 EDA、切分、線性模型和指標串成可重現流程。	使用 Playground 競賽資料；標題與版本分數可能不同，不搬用其分數當本地結果。
特徵總和與排序 [3]	研究資料生成機制；考慮總和、排序等對稱特徵。	競賽資料與此 50,000 筆版本不同；不複製其排行榜結論。
Ridge / Lasso	正則化在多重共線性或雜訊時可能有益。	此版本低共線性且目標近確定，懲罰會引入偏差。
梯度提升對照	同一分割實際執行 HistGradientBoosting，比較非線性彈性。	它不是所有樹模型的最佳調參結果，也不能代表 XGBoost / CatBoost 上限。
Conformal [5]	校準獨立殘差，明確區分點預測與區間涵蓋。	沒有真實時空資料，不能將交換性或外部涵蓋率視為已被驗證。

本作業的公平量化比較，僅採同一本地資料、同樣切分與 CV 的實際重跑分數。沒有引用外部 Kaggle 名次作自己的成績，也沒有宣稱主流複雜模型必然優於線性回歸。

限制與可改善方向

若目標是實際洪災預報，應先取得可驗證來源、有時間 / 地理標記與量測定義的資料，採時間或空間外推驗證，檢查分布漂移與各群組涵蓋率。對此教學版本增加模型複雜度，不能解決外部有效性不足。

7. NotebookLM 摘要與 AI 協作

NotebookLM 研究摘要（學生於 2026-10-16 貼回回答，經 GPT 核對與編修）

本研究依 NotebookLM 對 Kaggle Flood Prediction Dataset、scikit-learn 特徵選擇文件，以及 conformal prediction 論文的整理，使用 20 個環境與社會因素分數建立多元線性回歸，預測連續目標 FloodProbability [1][4][5]。特徵選擇可降低模型複雜度、減少無關欄位，但不保證提升準確度；應在訓練資料內比較 SelectKBest、RFE、SFS、Lasso 與 permutation importance，再由交叉驗證決定方案 [4]。此資料下載版本有 50,000 筆，輸入特徵為整數，而目標是浮點數，不能沿用來源頁「全部 int64」的誤述。95% split-conformal 預測區間利用獨立校準集的絕對殘差分位數建立，在資料交換性假設下提供有限樣本的邊際涵蓋率，並非每個固定地區或特定輸入都具有 95% 條件保證 [5]。資料上傳者承認原始出處、蒐集方法與地理覆蓋不明，故結果僅適合教學研究，不應直接用於實際防災 [1]。

GPT 核對與編修：修正目標 dtype、特徵選擇不必然改善表現，以及交換性與邊際涵蓋率的限制。上文引用編號對應報告參考來源。學生貼回的來源名稱共有三項，但未附 NotebookLM 可點選的引用標記或筆記本連結；本報告不宣稱已獨立查驗 NotebookLM 帳戶或筆記本。

7.1 GPT 輔助內容

GPT 協助釐清作業要求、查詢可取得的資料來源、建立與除錯 Python 程式、規劃不洩漏的模型比較、產生圖表、製作互動頁面與本報告。所有實驗數字取自實際執行輸出，不由文字模型填造。

學生貼回的 NotebookLM 回答已保存為 evidence/notebooklm_raw.txt 的閱讀版；Markdown 與公式轉為純文字。閱讀版用於來源對照，不是原始完整 GPT 對話 PDF。GPT 編修摘要與學生提供的研究內容分開標示，避免把核對改寫誤當 NotebookLM 原始逐字輸出。

7.2 原始回答核對

需修正內容	本報告採用的敘述
全部 int64	輸入為 int64；目標 FloodProbability 實際為 float64。
選特徵提高準確率	可能改善效率與泛化，但不保證；本次完整特徵最好。
任何新樣本都 95%	需交換性；邊際涵蓋，不是每個固定情境的條件保證。

8. Deployment | 部署與可重現操作

主程式：5115056023_hw2.py。先安裝 requirements.txt，執行主程式產生模型、圖表、CSV 和 dashboard_data.json；再執行 build_report.py 與 package_submission.py。

單筆預測：python predict_sample.py --input example_input.json。此程式載入 prediction_bundle.joblib，使用開發集正式模型及其獨立校準半寬。沒有在全部資料重訓後沿用舊區間。

網頁位於 web/index.html，可本機離線打開；部署後位於原 GitHub Pages 的 /hw2/ 子路徑。它只展示 Python 匯出的原始尺度係數，不在 GitHub Pages 執行 Python。舊 50 Startups 首頁保留。

依輸入觀測範圍標示外推；不自動把無效輸入當成零，不把未知分數包裝成真實洪災警報。

8.1 繳交完整性

項目	狀態
主程式、資料來源、圖表、評估	已執行並輸出
NotebookLM 摘要	學生已貼回研究回答，GPT 核對編修；未獨立查驗筆記本連結
完整 GPT 對話 PDF	待補：需本人匯出舊聊天與新聊天並確認完整
Kaggle 名次	未提交，無名次
最終可繳交狀態	待補完整原始對話 PDF，不可宣稱齊備

原始對話 PDF 請依 CONVERSATION_EXPORT_GUIDE.md 放入 evidence/ 並填寫本人確認的 conversation_manifest.json。build_report.py 只會合併實際存在且被確認的文件；不會以摘要或其他聊天內容充當完整紀錄。

參考來源與實驗紀錄

[1] Kamrul Hasan. Flood Prediction Dataset. Kaggle, version 1.

https://www.kaggle.com/datasets/kamrulhasan0077/flood-prediction-dataset

[2] Sakshi Satre. Flood Prediction Using Linear Regression. Kaggle notebook.

https://www.kaggle.com/code/sakshisatre/flood-prediction-using-linear-regression-0-84558/notebook

[3] broccoli beef. Sorting along the feature axis as feature engineering. Kaggle discussion.

https://www.kaggle.com/competitions/playground-series-s4e5/discussion/499579

[4] scikit-learn. Feature selection, official documentation.

https://scikit-learn.org/stable/modules/feature_selection.html

[5] Angelopoulos, A. N. & Bates, S. A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification. 2021, revised 2022.

https://arxiv.org/abs/2107.07511

來源可重現識別

下載日期：2026-10-16；版本：1；授權標示：CC0: Public Domain。

SHA-256: 9cf6a2339d7c7524620f99497801c278e3c1ed0aca8d0fde22a683508fa10e8d

執行環境

{"python": "3.13.15", "numpy": "2.5.4", "pandas": "3.0.6", "scipy": "1.18.1", "scikit-learn": "1.9.1"}

本次主程式執行約 23.1 秒，threadpool 限制 1 執行緒。實際分數保存於 CSV / JSON，不受報告四捨五入影響。

重要輸出

outputs/run_manifest.json：切分、設定與結果；cv_folds.csv：逐折分數；selected_features.json：選定欄位；test_predictions.csv：測試預測與區間；diagnostics.json 與 reduced_diagnostics.json：診斷適用限制；data/source.json 與 kaggle_metadata.json：來源。